- 01. 데이터 전처리 및 통합 분석 보고서
  - 프로젝트 개요
  - 1. 데이터 소스 및 설명
    - 1.1 사용 데이터셋
    - 1.2 원본 데이터 파일 구조
  - 2. 분석 대상 품목 정의
    - 2.1 소스류 원재료 매핑
    - 2.2 주요 생산국 목록
  - 3. 데이터 변수 설명
    - 3.1 생산량 데이터 변수
    - 3.2 기온 변화 데이터 변수
    - 3.3 통합 데이터셋 변수
  - 4. 데이터 전처리 과정
    - 4.1 전처리 파이프라인
    - 4.2 수행된 데이터 변환
      - 4.2.1 대용량 데이터 청크 처리
      - 4.2.2 연도 필터링
      - 4.2.3 피벗 테이블 변환
      - 4.2.4 기온 데이터 집계
      - 4.2.5 파생 변수 생성
  - 5. 출력 데이터 파일
    - 5.1 생성된 전처리 파일 목록
    - 5.2 핵심 출력 데이터 구조
      - 토마토 생산량 데이터 (tomatoes_production.csv)
      - 기온 편차 데이터 (temperature_processed.csv)
      - 통합 데이터셋 (sauce_ingredients_integrated.csv)
  - 6. 데이터 품질 검증 결과
    - 6.1 데이터 통계 요약
    - 6.2 데이터 무결성 확인
  - 7. 주요 발견사항 (데이터 기반)
    - 7.1 생산량 추세 (2000-2024)
    - 7.2 기온 변화 추세
    - 7.3 생산량 변동성 비교
  - 8. 다음 단계
  - 참고 문헌

01. 데이터 전처리 및 통합 분석 보고서

프로젝트 개요

항목	내용
프로젝트명	기후 변화가 햄버거 소스류 원재료에 미치는 영향 분석
분석 대상	토마토(케찹), 계란(마요네즈), 고추(스리라차)
핵심 메시지	"당신의 햄버거 소스 가격은 지구 반대편 기후에 달려있다"
분석 기간	2000년 ~ 2024년

---

1. 데이터 소스 및 설명

1.1 사용 데이터셋

데이터셋	출처	설명
FAOSTAT Crops Production	FAO	농작물 생산량, 재배면적, 수확량 데이터
FAOSTAT Livestock Primary	FAO	축산물(계란) 생산량 데이터
FAOSTAT Temperature Change	FAO	국가별 기온 변화(편차) 데이터 (NASA GISTEMP 기반)
Kaggle Climate Change Impact	Kaggle	기후 변화가 농업에 미치는 영향 데이터

1.2 원본 데이터 파일 구조

```
data/
├── Production_Crops_Livestock_E_All_Data_(Normalized)/  # FAOSTAT 생산량 데이터
├── Environment_Temperature_change_E_All_Data_(Normalized)/  # 기온 변화 데이터
├── climate_change_impact_on_agriculture_2024.csv  # Kaggle 기후-농업 데이터
└── ...
```

---

2. 분석 대상 품목 정의

2.1 소스류 원재료 매핑

소스	원재료	FAO Item Code	FAO Item Name	기후 민감도
케찹 (Ketchup)	토마토	388	Tomatoes	중간 (관개 시설 의존)
마요네즈 (Mayonnaise)	계란	1062	Hen eggs in shell	간접적 (사료 작물 영향)
스리라차 (Sriracha)	건고추	689	Chillies and peppers, dry	매우 높음 (가뭄, 폭염에 취약)
기타 소스	풋고추	401	Chillies and peppers, green	높음

2.2 주요 생산국 목록

품목	주요 생산국
토마토	중국, 인도, 터키, 미국, 이집트, 이탈리아
계란	중국, 미국, 인도, 멕시코, 브라질, 일본
건고추	인도, 중국, 방글라데시, 태국, 파키스탄, 멕시코
풋고추	중국, 멕시코, 터키, 인도네시아, 스페인

---

3. 데이터 변수 설명

3.1 생산량 데이터 변수

변수명	데이터 타입	단위	설명
`Year`	Integer	연도	데이터 수집 연도 (2000-2024)
`Area`	String	-	국가/지역명
`Item Code`	Integer	-	FAO 품목 코드
`Item`	String	-	품목명
`Element`	String	-	측정 요소 (Production, Area harvested, Yield)
`Value`	Float	톤/ha/kg/ha	측정값

3.2 기온 변화 데이터 변수

변수명	데이터 타입	단위	설명
`Year`	Integer	연도	기준 연도
`Area`	String	-	국가/지역명
`Months`	String	-	측정 기간 (Meteorological year)
`Value`	Float	°C	기온 편차 (기준 기간 대비)

3.3 통합 데이터셋 변수

변수명	데이터 타입	단위	설명
`Year`	Float	연도	데이터 연도
`Item_Key`	String	-	품목 식별 키 (tomatoes, eggs, chillies_dry, chillies_green)
`Item_Name`	String	-	품목 한글명
`World_Production_Tonnes`	Float	톤	전 세계 총 생산량
`Climate_Sensitivity`	String	-	기후 민감도 등급
`Temp_Anomaly_C`	Float	°C	해당 연도 기온 편차 (전 세계 평균)
`YoY_Change_Pct`	Float	%	전년 대비 생산량 변화율

4. 데이터 전처리 과정

4.1 전처리 파이프라인

```
원본 데이터 로드 → 청크 처리 → 품목 필터링 → 피벗 변환 → 기온 데이터 병합 → 통합 데이터셋 생성
```

4.2 수행된 데이터 변환

4.2.1 대용량 데이터 청크 처리

변환 내용	이유
청크 사이즈 500,000 rows로 분할 처리	FAOSTAT 원본 데이터가 수백만 행의 대용량 데이터이므로 메모리 효율적 처리 필요
필요한 Item Code만 실시간 필터링	전체 데이터를 메모리에 로드하지 않고 필요한 품목만 추출하여 처리 속도 향상

```
for chunk in pd.read_csv(production_path, chunksize=500000):
    filtered = chunk[chunk['Item Code'].isin(target_item_codes)]
```

4.2.2 연도 필터링

변환 내용	이유
2000년 이후 데이터만 사용	최근 25년간의 데이터에 집중하여 현대 기후 변화 영향 분석에 적합
기후 변화 가속화 시기와 일치	2000년대 이후 지구 온난화가 뚜렷하게 가속화된 시기

4.2.3 피벗 테이블 변환

변환 전	변환 후	이유
Long format (행 기반)	Wide format (열 기반)	국가별 시계열 비교 분석 용이
Area가 행으로 반복	Area가 열로 전개	시각화 및 상관관계 분석에 적합한 구조

```
df_pivot = df_elem.pivot_table(
    index='Year',
    columns='Area',
    values='Value',
    aggfunc='sum'
)
```

4.2.4 기온 데이터 집계

변환 내용	이유
월별 데이터 → 연간 평균	생산량 데이터가 연간 단위이므로 기온 데이터도 연간 단위로 집계
국가별 기온 편차 → 전 세계 평균(World_Avg)	전 세계적 기후 변화 추세와 생산량 관계 분석

4.2.5 파생 변수 생성

변수명	계산 방법	이유
`World_Total`	주요 생산국 생산량 합계	전 세계 총 생산량 추세 파악
`YoY_Change_Pct`	(금년 - 전년) / 전년 × 100	기후 변화에 따른 생산량 변동성 분석
`Temp_Anomaly_C`	기온 데이터 병합	생산량-기온 상관관계 분석

---

5. 출력 데이터 파일

5.1 생성된 전처리 파일 목록

파일명	크기	설명
`tomatoes_production.csv`	1.8 KB	토마토 생산량 (국가별, 연도별)
`tomatoes_area_harvested.csv`	1.5 KB	토마토 재배면적
`tomatoes_yield.csv`	1.4 KB	토마토 단위면적당 수확량
`eggs_production.csv`	2.2 KB	계란 생산량
`eggs_yield.csv`	1.3 KB	계란 생산 효율
`chillies_dry_production.csv`	1.9 KB	건고추 생산량
`chillies_dry_area_harvested.csv`	1.7 KB	건고추 재배면적
`chillies_dry_yield.csv`	1.5 KB	건고추 단위면적당 수확량
`chillies_green_production.csv`	1.5 KB	풋고추 생산량
`chillies_green_area_harvested.csv`	1.3 KB	풋고추 재배면적
`chillies_green_yield.csv`	1.2 KB	풋고추 단위면적당 수확량
`temperature_processed.csv`	10.6 KB	국가별 연간 기온 편차
`sauce_ingredients_integrated.csv`	11.3 KB	소스 원재료 통합 데이터셋
`climate_agriculture_processed.csv`	1.0 MB	Kaggle 기후-농업 데이터

5.2 핵심 출력 데이터 구조

토마토 생산량 데이터 (tomatoes_production.csv)

Year	China	India	USA	Egypt	Italy	World_Total
2000	22,324,773	7,430,000	12,622,261	6,785,640	7,538,100	56,700,774
...	...	...	...	...	...	...
2024	61,700,323	21,323,223	10,683,555	7,521,071	6,022,790	107,250,962

기온 편차 데이터 (temperature_processed.csv)

Year	China	India	USA	World	World_Avg
2000	0.41	0.29	0.66	0.48	0.41
...	...	...	...	...	...
2024	1.26	0.69	1.13	1.16	1.12

통합 데이터셋 (sauce_ingredients_integrated.csv)

Year	Item_Key	Item_Name	World_Production_Tonnes	Climate_Sensitivity	Temp_Anomaly_C	YoY_Chan
2000	tomatoes	토마토 (케찹)	56,700,774	중간 (관개 시설 의존)	0.41	-
2000	eggs	계란 (마요네즈)	639,800,983	간접적 (사료 작물 영향)	0.41	-
2000	chillies_dry	건고추 (스리라차)	1,705,281	매우 높음	0.41	-

6. 데이터 품질 검증 결과

6.1 데이터 통계 요약

데이터셋	행 수	컬럼 수	기간	결측치 비율
토마토 생산량	25	7	2000-2024	< 1%
계란 생산량	25	8	2000-2024	< 1%
건고추 생산량	25	8	2000-2024	< 1%
기온 편차	64	16	1961-2024	< 2%
통합 데이터	100	7	2000-2024	< 1%

6.2 데이터 무결성 확인

- **연도 연속성**: 모든 품목에서 2000-2024년 데이터 연속적으로 존재
- **국가 커버리지**: 주요 생산국 6개국 이상 데이터 확보
- **단위 일관성**: 생산량(톤), 기온(°C) 단위 통일

---

7. 주요 발견사항 (데이터 기반)

7.1 생산량 추세 (2000-2024)

품목	2000년 생산량	2024년 생산량	증가율
토마토	56,700,774 톤	107,250,962 톤	**+89%**
계란	639,800,983 개	1,104,405,717 개	**+73%**
건고추	1,705,281 톤	4,043,319 톤	**+137%**
풋고추	12,845,591 톤	25,107,979 톤	**+95%**

7.2 기온 변화 추세

연도	전 세계 평균 기온 편차
2000년	+0.41°C
2010년	+0.66°C
2020년	+0.81°C
2024년	**+1.12°C**

7.3 생산량 변동성 비교

품목	YoY 변화율 표준편차	기후 민감도
건고추	**10.8%**	매우 높음

품목	YoY 변화율 표준편차	기후 민감도
풋고추	3.2%	높음
토마토	4.1%	중간
계란	2.8%	간접적

결론: 건고추가 가장 높은 생산량 변동성을 보이며, 이는 기후 민감도와 일치함

---

8. 다음 단계

전처리된 데이터는 다음 분석 단계에서 활용됩니다:

1. **02_data_visualization.py**: 시계열 시각화, 국가별 비교, 상관관계 시각화
2. **03_data_analysis.py**: 통계 분석, 회귀 분석, 기후-생산량 상관관계 분석
3. **04_conclusion.py**: 종합 결론 및 인사이트 도출

참고 문헌

1. FAO. 2024. FAOSTAT: Crops and livestock products. https://www.fao.org/faostat/en/#data/QCL
2. FAO. 2024. FAOSTAT: Temperature change on land. https://www.fao.org/faostat/en/#data/ET
3. NASA Goddard Institute for Space Studies (GISTEMP)
4. Kaggle - Climate Change Impact on Agriculture Dataset